

פתרון תרגיל בית - התאמת מחרוזות וקונבולוציה

1. בהנתן טקסט T ותבנית P מעל א"ב בינארי, הסבירו כיצד ניתן בעזרת קונבולוציה

לספור כמה אותיות לא מתאימות יש בין הטקסט לתבנית בכל הזזה.

נמקו תשובתכם!

דוגמא – (מספר התווים הלא מתאימים בהזזה i): $C[i] =$

$i = 1\ 2\ 3\ 4\ 5\ 6\ 7\ 8\ 9\ 10$

$T = 1\ 1\ 0\ 1\ 0\ 0\ 1\ 1\ 1\ 1$

$P = 1\ 1\ 0$

$C[0] = 0$

$C[4] = 3$

$C[7] = 1$

פתרון

בתרגול ראינו אלגוריתם הסוכם את מספר האותיות הזרות שבין התבנית למחרוזת בכל הזזה, לכן אם נפחית מספר זה מ-m (גודל התבנית), נקבל את מספר האותיות הלא זרות

convolution_string_unmatcher(T,P)

1. $P' \leftarrow \text{Reverse}(P)$
2. $P' \leftarrow \text{PadWithZero}(P', \text{length}[T])$
3. $c_1 \leftarrow \text{convolution}(T, P')$
4. $\bar{P} \leftarrow \text{NOT}(P)$
5. $\bar{T} \leftarrow \text{NOT}(T)$
6. $\bar{P}' \leftarrow \text{Reverse}(\bar{P})$
5. $\bar{P}' \leftarrow \text{PadWithZero}(\bar{P}', \text{length}[\bar{T}])$
6. $c_0 \leftarrow \text{convolution}(\bar{T}, \bar{P}')$
7. **for** $i \leftarrow m-1$ **to** $\text{length}[c_1]$
8. **do print** " $c[i-m+1]=m - c_1[i] - c_2[i]$ "

נכונות

בהינתן טקסט T ותבנית P מעל א"ב בינארי, נראה שהפעלת האלגוריתם תדפיס את מספר אי ההתאמות בין הטקסט לתבנית באמצעות קונבולוציה.

הוכחנו בתרגול את הרדוקציה מבעיית התאמת המחרוזות לקונבולוציה. נרצה להראות שהשינויים שביצענו באלגוריתם שהוכחנו בכיתה, ידפיסו כמה אותיות לא מתאימות יש בין הטקסט לתבנית בכל הזזה. באלגוריתם המקורי, חישבנו את מספר ההתאמות בין התבנית לטקסט - לכן, אם נחסיר מספר זה מגודל התבנית m, נקבל את מספר אי ההתאמות בין התבנית לטקסט. עלות: $O(n \log n)$ - ניתן לבצע את הקונבולוציה באמצעות FFT בעלות זו.

2. הסבירו כיצד ניתן לשפר את עלות התאמת מחרוזות בעזרת קונבולוציה מ- $O(n \log n)$ ל- $O(n \log m)$.
 נבצע את הרדוקציה לקונבולוציה שראינו בתרגול עם שינויים קלים:

1. נחלק את הטקסט ל- $\frac{n}{2m}$ חלקים באורך $2m$ כל אחד עם חפיפה של m בין חלק לחלק
2. עבור כל חלק נפעיל את הרדוקציה לקונבולוציה שראינו בתרגול (תוכן הלולאה באלגוריתם המצורף) $O(m \log m)$

convolution string matcher(T,P)

1. $P' \leftarrow \text{Reverse}(P)$
2. $m \leftarrow \text{length}[P]$
3. $P' \leftarrow \text{PadWithZero}(P', \text{length}[2m])$
4. $T_index \leftarrow 0$
5. while $T_index + 2m \leq \text{length}[T]$
6. do
7. $c_1 \leftarrow \text{convolution}(T[T_index+2m], P')$
8. $\bar{P} \leftarrow \text{NOT}(P)$
9. $\bar{T} \leftarrow \text{NOT}(T[T_index+2m])$
10. $\bar{P}' \leftarrow \text{Reverse}(\bar{P})$
11. $\bar{P}' \leftarrow \text{PadWithZero}(\bar{P}', \text{length}[\bar{T}])$
12. $c_0 \leftarrow \text{convolution}(\bar{T}, \bar{P}')$
13. for $i \leftarrow m-1$ to $\text{length}[c_1]$
14. do if $c_1[i] + c_0[i] = \text{length}[P]$
15. then print "Pattern occurs with shift" $T_index + i - m + 1$
16. $T_index \leftarrow T_index + m$

נכונות

נראה שהפעלת האלגוריתם תשפר את זמן הריצה לסיבוכיות הרצויה מבלי לפגוע בנכונות האלגוריתם.
 נבצע $\frac{n}{2m}$ פעמים את הקונבולוציה שהוכחה בתרגול על חלקים בגודל $2m$ עם חפיפה של m כדי לאפשר לקונבולוציה לבצע הזזות גם בנקודות החיתוך בין החלקים, לכל הזזה של התבנית מול הטקסט יש קונבולוציה שביצעה באופן מלא את כל זוגות המכפלות המתאימות ויש סכום שמייצג את התוצאה בוקטור התוצאה c.

עלות: $O(\frac{n}{m} m \log m) = O(n \log m)$